

# Detekcija zamišljenih pokreta šake iz EEG signala

Svetlana Bačina, BI 38/2019,  
svetlana.bacina@best-eu.org

## I. UVOD

Komunikacija između čoveka i mašine je u poslednjim decenijama svakodnevna tema istraživanja biomedicinskog inženjerstva i neuronauke. Jedan od glavnih fokusa je razvoj metoda za prepoznavanje i dekodiranje mentalnih i fizičkih aktivnosti iz moždanih signala.

Važnu ulogu u ovim istraživanjima ima EEG. EEG je metoda snimanja električne aktivnosti mozga koja se postiže postavljanjem elektroda na skalp. Analiza EEG signala omogućava proučavanje moždane aktivnosti i otkrivanje uzoraka koji su povezani sa specifičnim mentalnim ili fizičkim aktivnostima.

EEG snimci tokom snimanja pokreta ruke mogu se koristiti kao kontrolni signali za BCI aplikacije kao što je kontrola kursora, izbor slova ili reči, kontrola proteze, navigacija invalidskih kolica itd.

Ovakva istraživanja imaju za cilj da osobama sa invaliditetom povećaju nezavisnost i time poboljšaju kvalitet života.

## II. BAZA PODATAKA

Baza koja je korišćena u ovom projektu “*EEG\_zad3.mat*” sadrži podatke nastale eksperimentalnim putem. Odrađeno je 90 pokušaja, gde svaki od tih pokušaja traje 8.3 sekunde, sa odbirkom 160 Hz. Zbog navedenog, dimenzije naše baze su **119520x30** (160\*8.3\*90). Prvi broj označava broj odbiraka sa kojima radimo, dok drugi predstavlja kanale SmartingProtocola. Kolona pod rednim brojem 26 predstavlja klase.

Svaki snimak sadrži stanje mirovanja koje traje 4,2 sekunde i fazu zamišljanja pokreta koja traje 4,1 sekund. Faza mirovanja je u koloni klase predstavljena 0, dok je faza pomeranja označena brojevima 1 i 2 (leva ruka i desna ruka, respektivno).

### A. ERD/ERS

ERD (Event-Related Desynchronization) i ERS (Event-Related Synchronization) su pojmovi koji se koriste u kontekstu analize elektroencefalografije (EEG) kako bi se opisali fenomeni promene moždane aktivnosti tokom određenih događaja ili stimulacija.

ERD se odnosi na smanjenje snage ili amplitude


elektroencefalograma u određenim frekvencijskim opsezima, dok se ERS, s druge strane, odnosi na povećanje snage ili amplitude EEG signala. Ove pojave su rezultat neuronske aktivnosti u moždanim regijama.

Dokazano je da izvršenje ili zamišljanje nekog voljnog pokreta uzrokuje ERS/ERD u frekvencijskim opsezima Alfa (8-13 Hz) i beta (13-30 Hz) ritmova motorne zone korteksa.

## III. OBRADA PODATAKA

### A. Pristup kanalima od interesa

Na osnovu naučne literature u ovoj oblasti, potrebno je izdvojiti signale sa kanala C3 i C4. Stoga smo indeksiranjem pristupili kanalima C3, C4, kao i pripadajućim klasama, putem indeksiranja (5, 6, 26, respektivno). Na slici 1. je prikazan izgled signala na datim kanalima.




Sl. 1. Prikaz signala na kanalima C3 i C4

### B. Filtriranje podataka

Kako ćemo obeležja vršiti iz vremenskom domenu, potrebno je da iz kanala C3 i C4 izvučeno frekvencijski opseg od interesa. Za svrhe filtriranja korišćen je Batervortov filter propusnik učestanosti drugog reda pomoću ugrađene *MATLAB* funkcije *butter* koja kao parametre prima red filtra, frekvencijski opseg, kao i tip filtra.

Kako se željeni signali nalaze u opsegu od 8 do 30 Hz, korišćićemo ‘*bandpass*’ filter. Koeficijente filtra ćemo koristiti u funkciji *filter* kako bismo primenili filter na signale C3 i C4. Na taj način dobijamo *C3\_filtrirano* i *C4\_filtrirano* (Slika 2.)



Sl. 2. Prikaz filtriranih signala sa kanala C3 i C4

### C. Izdvajanje obeležja

Po uzoru na rad "A study of the Naive Bayes classifier for analyzing imaginary movement EEG signals using the Periodogram as spectral estimator" J. Machado, A. Balbinot and A. Schuck, (doi: 10.1109/BRC.2013.6487514) odabrano je korišćenje periodograma u svrhe izdvajanja obeležja.

Kreirani su prazni vektori: *počeci\_pokreta* i *krajevi\_pokreta*, koji će se koristiti za skladištenje početnih i krajnjih tačaka perioda aktivnosti.

Pomoću petlje otkrivamo početke i krajeve. Logika petlje je da ukoliko je trenutna klasa 0, a sledeća nije 0, to znači da je početak perioda aktivnosti u pitanju. Analogno i za 1 i 2.

Inicijalizovani su prazni vektori: *alfa3*, *alfa4*, *beta3* i *beta4*, koji će sadržati statistička obeležja dobijena od različitih talasa i kanala. *Klase\_sjedinjeno* će sadržati sve prisutne klase u periodima. Pomoću petlje koja prolazi kroz indekse *početak\_pokreta* i *kraj\_pokreta* izdvajamo prozore signala C3 i C4.

Korišćenjem periodograma dobijamo spektralnu gustinu snage *pxx3* i *pxx4*.

Periodogram nam pruža informacije o tome kako se snaga signala raspoređuje u različitim frekvencijskim opsezima. Može nam pomoći da identifikujemo karakteristične frekvencijske komponente i obrasce aktivnosti u EEG signalu.

Konačno, *alfa3*, *alfa4*, *beta3* i *beta4* smeštamo u promenljivu *Vektor\_obeležja*. Dimenzije vektora obeležja su 4x90, gde uočavamo da smo obuhvatili svih 90 trial snimanja.

### D. Kros-validacija podataka

Metoda unakrsne validacije skup podataka za obuku se deli na približno k jednakih podskupova. Kao parametar *k*

koristićemo 5. Kako bi program mogao da podeli na približno jednake skupove, izračunavamo promenljivu *samplesPerFold* koja broj uzoraka (u ovom slučaju 90) deli sa *k* skupova (5).

Inicijalizujemo vektor *tačnost* pomoću funkcije *zeros*.

Pomoću petlje obračunavamo vrednosti za svih 5 podskupova.

Podelu podataka vršimo pomoću promenljivih *testIndices* i *trainIndices*. Pomoću formule

$((fold-1)*samplesPerFold+1 : fold*samplesPerFold)$ , smeštamo odgovarajuće indekse (1: *samplesPerFold*, 1+*samplesPerFold*: 2\**samplesPerFold*...) za *testIndices*.

Indekse skupova za trening dobijamo pomoću ugrađene funkcije *setdiff*, koja izdvaja indekse iz prvog koji nisu prisutni u drugom argumentu. Na taj način omogućavamo da podaci koji se nalaze u skupu za validaciju neće biti uključeni u skup za obuku.

Pomoću navedenih indeksa, kreiramo promenjive koje sadrže podatke za test i trening.

### E. Klasifikacija

Klasifikaciju vršimo pomoću tri različita klasifikatora: 'linear', 'diaglinear', 'quadratic'. Gde su linearni i kvadratni klasifikator po uslovu zadatka, a diagonalno-linearni klasifikator po izboru studenta.

Izbor klasifikatora se vrši pomoću radiobuttona u GUI aplikaciji.

Rezultati klasifikacije se smeštaju u promenljivu *klase\_koje\_smo\_dobili*. Kako se klasifikacija vrši unutar petlje unakrsne validacije, tačnost se čuva u promenljivoj "tačnost" za svaki podskup i kasnije se van petlje izračunava srednja vrednost tačnosti datog niza.

### F. Matrica konfuzije

Matrica konfuzije se izračunava pomoću ugrađene funkcije *confusionMatrix*. Zbog korišćenja kros validacije, bilo je potrebno akumulirati vrednosti za svih 5 podskupova. Pre ulaska u petlju inicijalizovana je matrica koja sadrži nule.

Unutar petlje su se vrednosti matrice ažurirale sa svakom iteracijom, te je konačna matrica konfuzije prikazana nakon izlaska iz petlje.

## IV. REZULTATI KLASIFIKATORA

Kako je pred nama bio problem binarne klasifikacije, evaluiraćemo ponašanje sva tri klasifikatora.

### A. Linearni klasifikator

Linearni klasifikator je jednostavan algoritam koji pokušava da nauči linearnu granicu koja razdvaja različite

klase podataka. Algoritam koristi linearnu kombinaciju obeležja kako bi doneo odluku pripadajućoj klasi ulaznih podataka.

Ovaj tip klasifikatora se odlikuje brzinom i jednostavnošću, ali nije pogodan za podatke koji nisu linearni.

U problemu klasifikacije koji je pred nama, najveći uspeh je imao baš ovaj klasifikator, sa tačnošću 62.2%. Matrica konfuzije je prikazana u Tabeli 1.

	Predviđene vrednosti	
Stvarne vrednosti	32	14
	20	24

Tabela 1. Matrica konfuzije za linearni klasifikator

Primećujemo da je češće prepoznavao zamišljenje pokrete leve ruke.

### B. Dijagonalni linearni klasifikator

Dijagonalni linearni klasifikator je modifikacija linearnog klasifikatora, gde se pretpostavlja da su vandijagonalni elementi matrice kovarijanse objedinjenog uzorka nula, odnosno pretpostavlja se da karakteristike nisu u korelaciji. Fleksibilnija je od linearnog klasifikatora.

Uspeh ovog klasifikatora se odlikuje tačnošću od 62.2%, a njegova matrica konfuzije je prikazana na tabeli 2.

	Predviđene vrednosti	
Stvarne vrednosti	34	12
	22	22

Tabela 2. Matrica konfuzije za dijagonalni linearni klasifikator

### C. Kvadratni klasifikator

Kvadratni klasifikator je složeniji algoritam koji koristi kvadratnu površinu odlučivanja za razdvajanje merenja dve ili više klasa objekata ili događaja.

Ovaj klasifikator modelira kovarijacione matrice različitih klasa, bez pretpostavke o njihovoj strukturi. Može se nositi sa nelinearnim granicama između klasa i ima veću fleksibilnost u modeliranju podataka.

Međutim, kvadratni klasifikator ima više parametara za naučiti i može biti sklon preprilagođavanju (overfitting) ako broj obeležja nije dovoljno velik u odnosu na broj uzoraka.

Primenom kvadratnog klasifikatora dobijamo tačnost od 53.33%. Matrica konfuzije je prikazana u tabeli 3.

	Predviđene vrednosti	
Stvarne vrednosti	21	25
	17	27

Tabela 3. Matrica konfuzije za kvadratni klasifikator